



VLA, Physical AI의 실현


조준호 (sudoremove )

250814 Physical AI Workshop



TESLA






자율주행의 첫번째 레슨

Modular vs End-to-End

ex) Mobileye, Tesla

모듈형 접근은 규칙과 단계에 의존하지만,
End-to-End 접근은 복잡하고 비정형적인 환경에서의
해법을 방대한 주행 데이터를 통째로 학습해 찾아낸다



자율주행의 첫번째 레슨

End-to-End 접근은 복잡하고 비정형 환경의 해법


- 예외/돌발 상황이 너무 많아 Rule 기반으로는 대응 불가



- 사람이 감각기관으로 운전을 한다면, 기계도 가능하다는 가정

- 데이터 기반 모방 학습

Imitation Learning



Elon Musk

"인간은 눈과 생물학적 신경망으로 운전합니다.
따라서 자율주행의 일반화된 해법은
카메라와 실리콘 신경망을 사용하는 것이 합리적입니다."



자율주행의 첫번째 레슨


End-to-End 자율주행 모델의 **입력**과 **출력**



주행 영상 + 현재 위치 + 목적지




자율주행 모델



조향값 + 속도




$$\Delta v, \Delta \delta$$



정형 Task

coffee making



fix bike?

비정형 Task




autonomous, 2x speed

fold laundry

자율주행의 첫번째 레슨

End-to-End 로봇 (robot policy)의 입력과 출력



관측 영상 + 지시어 + 로봇 관절값



전방 카메라




왼쪽 그리퍼 카메라




오른쪽 그리퍼 카메라


"티셔츠를 접어라"



Robot policy



Robot action



$\Delta x, \Delta \theta, \Delta grip$

첫번째 레슨

자율주행 e2e → 로봇 e2e

공통점: **복잡하고 비정형 환경의 해법**

용어 교통 정리



- ▶ **VLA (Vision Language Action model):**
Vision-Language 입력으로 Action을 출력하는 모델

인터넷 규모의 데이터로 학습한 VLM (Vision-Language Model) 의 시각적·언어적 지식을 활용하면서,
로봇의 저수준 동작(*low-level actions*)을 예측할 수 있도록 확장한 모델

- ▶ **RFM (Robot Foundation Model)**

어떤 로봇이든, 어떤 작업(*task*)이든 수행할 수 있도록
다양한 환경·센서·action 데이터를 대규모로 사전학습한 범용 로봇 지능 모델.
VLA의 궁극적인 지향점


- ▶ **LAM / LBM:** VLA로 취급

Large Action Model
Large Behavior Model

지금 VLA에 대한 기대감의 이유





- 휴머노이드, 로봇 비정형 Task데모의 급진적 향상




오픈소스된 pi0 모델을 Astribot 로봇에서 캡슐커피 내리는 Task를 파인튜닝

- 오픈 weight VLA모델 (ACT, OpenVLA, π_0 pizero) 공개로 진입장벽 하락


- 저가형 오픈소스 로봇
 - + 텔레옴/학습/구동 플랫폼
- HuggingFace LeRobot



Vision-Language-Action model




$$f_{\theta} \rightarrow$$



"티셔츠를 접어줘"

Vision-Language-Action model


(Vision+Language → Action) 의 방대한 데이터셋에서 모방 학습 전략



VLA 진화 과정


Action 생성의 발전 : binning

- Action binning (RT1,2 OpenVLA) :
0~1 값의 action을 1/256 binning,
discrete token 으로 출력



(+) LLM으로 액션 시퀀스 예측 가능

(-) 속도와 성능이 아쉽




OpenVLA: An Open-Source Vision-Language-Action Model, 2024
<https://openvla.github.io/>

VLA 진화 과정

Action 생성의 발전 : binning→chunking→diffusion/flow

Action Chunking Transformer


action sequence를 chunk로 예측




Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware, RSS2023
<https://tonyzhaozh.github.io/aloha/>

Diffusion policy, Flow matching

*빨간, 파란 경로 둘다 가능한 경로




Diffusion Policy: Visuomotor Policy Learning via Action Diffusion, RSS2023
<https://diffusion-policy.cs.columbia.edu/>



VLA 진화 과정

더 많은 robot embodiment / task 데이터

- Open-x embodiment



21개 기관, 22개 *Robot Embodiments*, 60개 *Datasets*
1M+ 로봇 궤적, 160k+ Tasks


VLA 진화 과정

Multi-task learning

Pre-trained VLA > scratch VLA 보다 우수




Train "single-task" Diffusion Policy as one long task with 229 demonstrations



π_0 : A Vision-Language-Action Flow Model for General Robot Control
<https://www.physicalintelligence.company/blog/pi0>

Finetuning to unseen tasks (sim)




A Careful Examination of Large Behavior Models for Multitask Dexterous Manipulation
<https://toyotaresearchinstitute.github.io/lbm1/>

VLA 수렴 진화

Pre-trained VLM + DiT + Multi-task

Physical Intelligence, π_0


Physical Intelligence (π)



VLA 수렴 진화

Pre-trained VLM + DiT + Multi-task


NVIDIA, n1 . 5 gr00t



VLA 수렴 진화


Pre-trained VLM + DiT + Multi-task

Toyota Research Institute, Large Behavior Model



VLA의 Deployment

Act & Observe



VLA의 장점, 포텐셜

+ data-driven imitation learning



1x speed | Autonomous

Astribot

- ▶ 로봇의 비정형 task가 가능성
- ▶ Generalist policy, **Robot Foundation Model** 가능성,
- ▶ Finetuned Specialist policy는 scratch training 보다 우수

VLA의 현재 한계

생각보다 ... 많다

- ▶ Data: teleoperation cost, quantity
- ▶ Poor instruction following
- ▶ Lack of memory / history
- ▶ Evaluation cost
- ▶ Reliability, hard to achieve 99.99%

When you don't give a language command...



Stanford

<https://youtu.be/TN1M6vg4CsQ?si=QjpnhjG9Ua5Si1fg&t=2900>

<Keynote> Physical AI, 가시권에 접어든 휴머노이드

ROBROS

이미지 to 액션 방식의 기억력 문제

박현준
로브로스 이사

AX 시대, Agentic AI와 Physical AI로 향하는 미래 비즈니스

This presentation material was provided by Agenetic Park, ROBROS Inc. for ITF Korea Version 2020, May 16, 2020. Contact : info@robros.co.kr

주최 IITP 정보통신기획평가원 전자신문 후원 과학기술정보통신부 경상북도부 산업부 중소벤처기업부 KISTI 한국과학기술정보연구원 KIAF 한국국제농업전시회 KISA 한국인터넷진흥원 KISTIA 한국과학기술정보통신부 KISTI 한국과학기술정보통신부

https://youtu.be/PZpf17oIVXk?si=u7PC_YIlbsW3cSOy&t=1370



두번째 레슨: *Inductive Bias for VLA*


센서/하드웨어 선택

- 자율주행의 오래된 논장
LiDAR vs Vision only

정확도, 안정성, 비용, 환경 적응성

- VLA 시사점:



어떤 Task에 따라
proprioception, tactile, depth 등
센서 조합, 하드웨어의 결정이 필요



두번째 레슨: *Inductive Bias for VLA*



*Inductive bias: 모델이나 시스템이 세상을 해석하는 기본 가정과 제약, 모델 설계의 가정

- ▶ 센서 선택, 로봇 embodiment 설계
 - ▶ 접근 (Reaching) : Stereo camera? Depth? LiDAR?
 - ▶ 파지 (Grasp) : Tactile force feedback? 초음파? 소리?
- ▶ Humanoid VS Non-humanoid



두번째 레슨: *Inductive Bias for VLA*

- ▶ 모델 아키텍쳐
 - ▶ 예를 들어, 현재 프레임뿐만 아니라 최근 시각·동작 history



FigureAI Helix

세번째 레슨: Scalability

대규모 데이터 확보와 확장성 있는 모델 평가 방법

- 자율주행 수십~수백만 km 주행 데이터 필요. *Tesla는 fleet 도 운용.
- VLA 시사점: 고품질 다량 Tele-operation, 시뮬레이터 데이터 혼합 전략 필요



Evaluation: Simulation-based testing



Scenario 1: Drying Rack



Scenario 2: Shelf



Scenario 3: Breakfast



A Careful Examination of Large Behavior Models for Multitask Dexterous Manipulation
<https://toyotaresearchinstitute.github.io/lbm1/>

TRI LBM:
 sim data를 co-train한 이유는
 sim에서 eval 하기 위해서

Real World에서 Evaluation cost 매우 높음


세번째 레슨: *Scalability*

당장 좋은 퀄리티의 teleop 데이터를 모아야한다.



*teleop도 연구 분야중 하나
teleop 데이터를 마치 LLM의 web-scale로 모을 수 있는가?

테슬라가 시간당 48달러,
휴머노이드 로봇 ‘Optimus’ teleoperator에게 지급



5'7"~5'11"(약 170~180cm)
하루 7시간 이상 걷기와 최대 30파운드(약 13.6kg) 하중 운반이
가능한 체력이 요구됩니다.

<https://interestingengineering.com/culture/tesla-paying-to-train-optimus-robot>

세번째 레슨: Scalability

합성·시뮬레이션 데이터

simulation

대규모 실물 시연을 모으는데 비용이 커서,


합성 영상·시뮬레이터로 ‘무한’ 데이터를 뽑아내는 노선
(ex. GR0OT N1.5)



Pick up the apple, place it into the drawer and close the drawer.



Pick up eggplant from placemat to plate.



Pick the carrot from the sink and place it on the plate located on the counter.



Pick the teapot from the counter and place it in the sink.

<https://research.nvidia.com/labs/gear/flare/>
<https://research.nvidia.com/labs/gear/dreamgen/>

세번째 레슨: Scalability

액션 라벨 없는 사람의 비디오에서 학습

web, video



TESLA

Milan Kovac @_milankovac_ · Follow

X

One of our goals is to have Optimus learn straight from internet videos of humans doing tasks. Those are often 3rd person views captured by random cameras etc.

We recently had a significant breakthrough along that journey, and can now transfer a big chunk of the learning [Show more](#)

Tesla Optimus @Tesla_Optimus

I'm not just dancing all day, ok

Fully Autonomous 1.5x


Optimus is learning many new tasks

1:35 PM · May 21, 2025

10.6K Reply Copy link to post



Read 535 replies

https://x.com/_milankovac_/status/1925047791954612605



세번째 레슨: Scalability

World Model * 현재 시간 t 에서의 Observation, Action으로 다음 시간 $t+1$ 에서의 Observation을 예측하는 모델





세번째 레슨: Scalability

World Model

* Data 가 많을 수록 정교한 World Model 학습 가능



VLA의 *evaluation*을 eval cost 높은 실제 환경 대신에 *World model*에서 proxy 평가

<https://www.1x.tech/discover/redwood-ai-world-model>

세번째 레슨: *Scalability*

World Model, Model-based RL

- Teleop은 사실 완벽한 고품질 데이터는 아님
*자신의 신체가 아닌 것을 조종
- 모방 학습의 한계
- 더 효율적인 행동을 Embodied Agent가 World Model 내에서 탐색할 수 있다면?



<https://deepmind.google/discover/blog/genie-3-a-new-frontier-for-world-models/>

Genie 3 Prompt:

"POV action camera of a tan house being painted by a first person agent with a paint roller"

* robot agent의 시점이라면?

세번째 레슨: *Scalability*

World Model, Model-based RL

Embodied Agent가 **World Model**에서 여러 가상 시뮬레이션(**rollout**)을 수행

이를 통해 효율적인 action을 탐색하고 **강화학습(RL)**에 활용

모방학습(IL)만으로는 어려운 일반화·탐색 문제를 극복할 수 있음

LLM 발전 과정에서의 교훈과 유사 (**SFT + RLVR**)





네번째 레슨: Business Strategy

시장 진입 순서

Specialist → Generalist

자율주행

ADAS (Advanced Driver Assistance System)

제한된 환경(고속도로, 저속 주차 등)에서 안정성 확보

Highway Pilot / 특정 환경 자율주행

‘제한된 맵’ + ‘고정된 조건’에서 신뢰성 향상

FSD (Full Self-Driving)

비정형 환경 대응

Robot Foundation Model

Specialist VLA

반복적, 구조화된 환경에서 동작 *공장, 물류센터, 단순 가사 로봇

Semi-generalist VLA

환경/작업 범위를 점차 확장 Multi-task 학습,

Generalist RFM

새로운 환경, Multi-embodiment, multi-task 수행

네번째 레슨: *Business Strategy*

전략적 유사점

- ▶ 제한된 환경에서 먼저 성공사례 만들기 (자율주행의 고속도로, 로봇의 공장/물류)
- ▶ ROI 빠른 곳부터 진입 (투자자 설득)
- ▶ 데이터를 Scalable하게 모으는 방법 고안



**자율주행이 "도로" 정복하려는 도전이라면,
RFM은 "실제 세계" 정복하려는 도전**

감사합니다

